

# Exercício 1: Análise da Fronteira de Decisão em Modelos Generativos

## (a) Fronteira de Decisão com Covariâncias Diferentes e Priors Iguais

A probabilidade posterior de uma classe  $C_k$  dado um vetor de features  $\mathbf{x}$  é dada pelo Teorema de Bayes:

$$p(C_k|\mathbf{x}) = \frac{p(\mathbf{x}|C_k)p(C_k)}{p(\mathbf{x})}.$$

A fronteira de decisão ocorre quando  $p(C_1|\mathbf{x}) = p(C_2|\mathbf{x})$ . Assumindo priors iguais  $p(C_1) = p(C_2) = 0.5$ , esta condição se simplifica para  $p(\mathbf{x}|C_1) = p(\mathbf{x}|C_2)$ .

As densidades condicionais de classe são Gaussianas Multivariadas:

$$p(\mathbf{x}|C_k) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}_k|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)\right).$$

Igualando  $p(\mathbf{x}|C_1) = p(\mathbf{x}|C_2)$  e tomando o logaritmo natural de ambos os lados, obtemos:

$$\begin{aligned} & -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}_1^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) - \frac{1}{2} \ln |\boldsymbol{\Sigma}_1| \\ & = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}_2^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) - \frac{1}{2} \ln |\boldsymbol{\Sigma}_2|. \end{aligned}$$

Multiplicando por -2 e rearranjando, a equação da fronteira de decisão é:

$$(\mathbf{x} - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}_1^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) + \ln |\boldsymbol{\Sigma}_1| = (\mathbf{x} - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}_2^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) + \ln |\boldsymbol{\Sigma}_2|.$$

Expandindo os termos quadráticos, temos:

$$\mathbf{x}^T \boldsymbol{\Sigma}_1^{-1} \mathbf{x} - 2\boldsymbol{\mu}_1^T \boldsymbol{\Sigma}_1^{-1} \mathbf{x} + \boldsymbol{\mu}_1^T \boldsymbol{\Sigma}_1^{-1} \boldsymbol{\mu}_1 + \ln |\boldsymbol{\Sigma}_1| = \mathbf{x}^T \boldsymbol{\Sigma}_2^{-1} \mathbf{x} - 2\boldsymbol{\mu}_2^T \boldsymbol{\Sigma}_2^{-1} \mathbf{x} + \boldsymbol{\mu}_2^T \boldsymbol{\Sigma}_2^{-1} \boldsymbol{\mu}_2 + \ln |\boldsymbol{\Sigma}_2|.$$

Reorganizando os termos envolvendo  $\mathbf{x}$ , obtemos:

$$\mathbf{x}^T (\boldsymbol{\Sigma}_1^{-1} - \boldsymbol{\Sigma}_2^{-1}) \mathbf{x} - 2(\boldsymbol{\mu}_1^T \boldsymbol{\Sigma}_1^{-1} - \boldsymbol{\mu}_2^T \boldsymbol{\Sigma}_2^{-1}) \mathbf{x} + (\boldsymbol{\mu}_1^T \boldsymbol{\Sigma}_1^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \boldsymbol{\Sigma}_2^{-1} \boldsymbol{\mu}_2 + \ln |\boldsymbol{\Sigma}_1| - \ln |\boldsymbol{\Sigma}_2|) = 0.$$

Esta é uma função quadrática de  $\mathbf{x}$ , e a forma geométrica desta fronteira é uma **\*\*hiperquadrica\*\***. Casos específicos incluem hiperboloides, paraboloides ou elipsoides, dependendo das matrizes de covariância e dos vetores de média.

## (b) Efeito da Alteração do Prior com Covariâncias Compartilhadas

Se as covariâncias são compartilhadas,  $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}$ , e os priors são  $p(C_1) = \pi$  e  $p(C_2) = 1 - \pi$ , a condição para a fronteira de decisão  $p(\mathbf{x}|C_1)p(C_1) = p(\mathbf{x}|C_2)p(C_2)$  torna-se:

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_1, \boldsymbol{\Sigma})\pi = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_2, \boldsymbol{\Sigma})(1 - \pi).$$

Tomando o logaritmo natural de ambos os lados:

$$\begin{aligned} & -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) - \frac{1}{2} \ln |\boldsymbol{\Sigma}| + \ln \pi \\ & = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) - \frac{1}{2} \ln |\boldsymbol{\Sigma}| + \ln(1 - \pi). \end{aligned}$$

Os termos envolvendo  $|\Sigma|$  se cancelam, e expandindo os termos quadráticos:

$$-\frac{1}{2}(\mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2\boldsymbol{\mu}_1^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1) + \ln \pi = -\frac{1}{2}(\mathbf{x}^T \Sigma^{-1} \mathbf{x} - 2\boldsymbol{\mu}_2^T \Sigma^{-1} \mathbf{x} + \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2) + \ln(1 - \pi).$$

Os termos  $\mathbf{x}^T \Sigma^{-1} \mathbf{x}$  também se cancelam. Multiplicando por -2 e rearranjando, obtemos a fronteira de decisão linear:

$$(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \Sigma^{-1} \mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2) + \ln\left(\frac{\pi}{1 - \pi}\right) = 0.$$

O termo  $\ln\left(\frac{\pi}{1 - \pi}\right)$  é um deslocamento escalar na equação linear. Geometricamente, \*\*alterar o prior  $\pi$  resulta em um deslocamento paralelo da fronteira de decisão linear\*\*.

- Se  $\pi > 0.5$  (ou seja,  $p(C_1) > p(C_2)$ ), então  $\ln\left(\frac{\pi}{1 - \pi}\right) > 0$ . Para satisfazer a equação, o valor de  $(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \Sigma^{-1} \mathbf{x}$  precisa ser menor para um dado  $\mathbf{x}$ , o que significa que a fronteira se desloca em direção à região onde  $p(\mathbf{x}|C_1)$  é menor em relação a  $p(\mathbf{x}|C_2)$ . Intuitivamente, como  $C_1$  é mais provável a priori, a região classificada como  $C_1$  se expande.
- Se  $\pi < 0.5$  (ou seja,  $p(C_1) < p(C_2)$ ), então  $\ln\left(\frac{\pi}{1 - \pi}\right) < 0$ , e a fronteira se desloca na direção oposta, expandindo a região de  $C_2$ .
- Se  $\pi = 0.5$ , o termo logarítmico é zero, e a fronteira é determinada apenas pelas médias e pela covariância compartilhada.

### (c) Uso da Distância de Mahalanobis para Classificação com Dois Modelos Gaussianos

Se tivéssemos um modelo Gaussiano para a classe normal ( $C_1$ ) com parâmetros  $\boldsymbol{\mu}_1, \Sigma_1$  e outro para a classe fraude ( $C_2$ ) com parâmetros  $\boldsymbol{\mu}_2, \Sigma_2$ , a distância de Mahalanobis  $\Delta_k^2 = (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k)$  para cada classe poderia ser usada para classificação com base na probabilidade posterior.

Uma abordagem seria usar a distância de Mahalanobis para calcular a densidade de probabilidade para cada classe e então usar o Teorema de Bayes para determinar a probabilidade posterior de cada classe dado um novo ponto  $\mathbf{x}$ :

$$p(C_k|\mathbf{x}) \propto p(\mathbf{x}|C_k)p(C_k) \propto \frac{1}{|\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}\Delta_k^2\right) p(C_k).$$

Poderíamos então classificar  $\mathbf{x}$  na classe com a maior probabilidade posterior. Se assumirmos priors iguais,  $p(C_1) = p(C_2)$ , a classificação se basearia em qual das densidades  $p(\mathbf{x}|C_k)$  é maior, o que está relacionado à distância de Mahalanobis e ao determinante da matriz de covariância.

Outra forma seria definir um limiar nas distâncias de Mahalanobis. Por exemplo, se modelarmos a classe normal ( $C_1$ ) e considerarmos qualquer ponto com uma distância de Mahalanobis acima de um certo limiar como uma anomalia (fraude), isso implicitamente assume algo sobre a distribuição da classe fraude. Se tivéssemos um modelo para ambas as classes, poderíamos comparar suas distâncias relativas, possivelmente ponderadas pelos priors.

As premissas implícitas ao usar modelos Gaussianos e a distância de Mahalanobis para classificação neste cenário incluem:

- \*\*Cada classe (normal e fraude) pode ser adequadamente modelada por uma distribuição Gaussiana multivariada.\*\* Isso significa que os dados dentro de cada classe estão concentrados em torno de uma média e a dispersão pode ser descrita por uma matriz de covariância.
- \*\*As matrizes de covariância  $\Sigma_1$  e  $\Sigma_2$  são inversíveis (não singulares).\*\* Isso é necessário para calcular a distância de Mahalanobis.
- \*\*Se priors diferentes forem usados, eles devem ser estimados ou conhecidos.\*\* A decisão ótima depende não apenas das probabilidades condicionais, mas também das probabilidades a priori das classes.
- \*\*A fronteira de decisão baseada em modelos Gaussianos (como derivado em (a)) é apropriada para separar as classes.\*\* Se as verdadeiras distribuições das classes se desviarem significativamente da forma Gaussiana, essa fronteira pode não ser ótima.

Em essência, ao usar a distância de Mahalanobis dentro de um arcabouço Bayesiano com modelos Gaussianos, estamos assumindo que a probabilidade de um ponto pertencer a uma classe diminui exponencialmente com o quadrado da sua distância de Mahalanobis do centro daquela classe, levando em conta a forma da distribuição (através da matriz de covariância).